

以算法放大模型的 数学研究能力

长期研究指导报告

面向初学者的修订稿

2026 年 9 月 18 日 · 指导报告 1.1

我们希望实现什么

算法是把输入变成输出的一组明确步骤。人工智能模型是经过训练、能够根据输入生成分析或答案的计算系统。本文主要讨论能够理解和生成文字的语言模型。

本项目希望研发可以重复使用的数学算法，让成本较低的模型，在限定时间内完成能力较强的模型花更长时间仍未完成的数学任务。报告沿用项目讨论中的“5.6”和“Astra”作为两个模型的称呼；真正比较时，需要写清它们的具体版本和使用设置。

“5.6 在半小时内完成 Astra 八小时未完成的任务”是长期挑战目标，目前还没有实验支持。接下来的研究要逐步建立证据，判断什么方法能够让这个目标成为可能。

阅读这份报告后，应能回答三个问题

- 可复用方法为什么可能提高模型解决数学问题的能力？
- 我们已经验证了什么，下一步应该研究什么？
- 怎样判断一次改进有效，并值得继续投入？

导读 | 先理解问题，再选择框架

这份报告用于指导后续研究，也用于让第一次接触项目的人了解工作方法。它不要求读者预先掌握高级数学；涉及已有成果的专业概念，会在使用之前解释。数学细节可以沿文末来源继续查阅。

为了把算法用于实际研究，需要区分三个概念。**工具**是把某种方法做成可调用的操作，说明它接受什么输入、何时适用、会返回什么。模型与工具共同完成任务的整体，本文称为**系统**。**框架**是组织这些部分的方式，规定谁负责选择方法、谁执行计算、谁检查结论，以及失败之后怎么办。

本项目希望改进的既包括算法，也包括框架。计算程序变快，可以节省一次运算的时间；框架选对研究方向，则可能避免大量无效运算。两种收益都值得研究，但需要分别验证。

阅读阶段	对应章节	要解决的疑问
理解目标与例子	第 1-3 节	我们要提高什么能力？数学工具怎样工作？
看清项目起点	第 4-5 节	已有数字代表什么，哪些能力还未验证？
选择研究方向	第 6-11 节	系统如何组织？有哪些思路和参考项目？
制定工作规则	第 12-16 节	怎样检查成果、比较成本、继续改进和判断贡献？

文中的 [P1] 等编号指项目内部证据，[R1] 等编号指已有论文或项目资料，链接集中在附录。本文将已有结果、工作建议和待验证的设想分别说明；后续可以修订建议，但应记录改变判断的依据。

1 | 目标：把模型的判断变成可完成的研究

为什么只增加推理时间可能不够

数学研究不仅需要计算，还需要选择表达问题的方法、找出有用的中间结论，并检查论证是否覆盖了全部情况。模型即使反复尝试，也可能一直使用不适合的方法，或者得到很好的近似，却无法证明近似有多准确。

工具希望承担两类工作。第一类是重复而明确的步骤，例如重复计算、检查不等式和保存已经验证的结果。第二类是研究中的选择，例如发现当前近似哪里不够好，并建议换一种表达或补充一条证明。第二类更接近本项目的长期目标，也更需要在新题上检验。

怎样逐步接近长期挑战

为了知道改进是否有效，需要一个基线：事先选定、具有合理能力的比较对象，例如同一模型使用常规数学软件的表现。“较弱”和“较强”应根据相关任务上的基线表现判断；“较低成本”则根据实际花费判断。模型便宜，不一定在每道题上都更弱。

第一步验证**工具价值**：同一模型面对相同题目时，新工具是否让它更容易完成任务。第二步验证**迁移能力**：在没有参与工具开发的新题中，这种帮助是否仍然存在。第三步验证**跨模型优势**：较低成本模型加新工具，是否能在预先规定的任务与资源条件下，超过较强模型加合理常规工具的表现。

第三步对应原始愿景，前两步帮助解释优势从哪里来。工具即使暂时没有达到第三步，也可能具有独立价值；但不能把前两步的成功写成长期挑战已经实现。

“做不到”应该怎样表述

实验中的“做不到”，只表示某个系统在指定题目、版本和预算内没有通过完成检查；预算指允许使用的时间、费用和计算资源。若一个系统 30 分钟成功，另一个系统 8 小时仍未完成，后者的实际解题时间依然未知，不能据此计算精确的加速倍数，更不能判断它永远无法解决。

研发工具时可以借助强模型和人工研究。正式测试低成本模型时，如果还需要强模型临时帮助，应把它记作另一种系统，并计入成本。这样才能知道，优势究竟来自工具积累，还是来自测试期间额外获得的帮助。

2 | 一个贯穿全文的例子：答案与证据一起改进

先看一个简单任务

假设我们要计算某个未知数，并保证误差足够小。为了说明概念，先用平方根作为教学例子：因为 1.414^2 小于 2，而 1.415^2 大于 2，所以 $\sqrt{2}$ 位于 $[1.414, 1.415]$ 中。这个简单例子不是本项目的研究成果。

方括号表示区间，即包含两个端点及其间所有数的范围。左端点是下界，表示目标不会更小；右端点是上界，表示目标不会更大。区间宽度等于上界减下界，这里是 0.001。只有端点关系有可靠依据，这个范围才能用来保证答案的准确程度。

候选解是目前找到、准备进一步检查的答案。误差估计是说明候选与真实目标最多可能相差多少的依据。如果已经证明目标在某区间内，取区间中点作为近似数，那么误差最多为区间宽度的一半。

工具返回的不应只有一个数

为了支持结论，工具可以保存端点、计算结果及所用条件。这种供程序或人复查的证据数据，称为**证书**。按规定检查证书是否支持结论的程序，称为**验证器**。验证器接受了证书，本文称为**认证**；它仍依赖所用数学规则、程序实现和输入条件的正确性。

因此，一个有用的返回结果应同时说明：目标是什么、候选是什么、有哪些上下界、这些界根据什么成立，以及还缺少什么。暂时无法证明时，应明确报告“未知”，而不是把一个看起来很准的小数当作保证。

精度停滞时，可能有两种不同原因

第一种原因是候选本身不够好。例如可以给出更好的上界，却还没有找到它。这时应该改进产生候选的方法。

第二种原因是候选已经很好，但证明太弱，给出的下界离它很远。这时反复修改候选可能帮助很小，更值得寻找一条能加强下界的论证。

本项目要发展的一项核心能力，就是让系统区分这两种情况，并选择值得尝试的下一步。后面出现的数学问题更复杂，但仍沿用“寻找对象、检查证据、定位缺口”的思路。

3 | 理解当前算例所需的数学概念

从数换成函数

函数可以理解为按规则给每个输入分配一个值的对象。本文常把几何表面上的位置作为输入，把该位置的数值作为输出。几何分析就是用函数、方程和不等式研究形状及其性质的数学方向。

当前主要算例所在的形状是单位球面，即三维空间中与球心距离等于 1 的所有点组成的表面。球面上的高度记作 z ，取值从 -1 到 1； $z=0$ 对应赤道。

并非所有函数都允许参与求解。把满足规定条件的函数放在一起，称为函数空间。当前使用的零均值空间要求函数在整个球面上的平均值为零，同时还要满足原题对整体大小和变化程度等方面的条件。平均值为零允许函数有正有负，并非要求处处为零。定义域一词在这里指某种运算可以合法作用的输入集合，不能仅凭函数有数值就认为所有运算都合法。

我们究竟要估计什么

能量在本文中是按数学规则从函数计算出的一个数，用来评价它，不一定代表真实物理能量。算子是把一个函数变成另一个函数的运算规则，例如求导，也就是计算函数随输入变化的快慢，得到的结果称为导数。某些问题可以写成 $Hu = \lambda u$ ： H 是算子， u 是一个非零函数， λ 是一个数；满足这个关系的 u 和 λ 分别称为特征函数和特征值。

谱是与算子相关的一组可能值，在当前球面问题中可通过特征值来理解。最低谱值在本算例里可以理解为：在全部允许的零均值函数中，先统一函数大小，再寻找能量能够达到的最低水平；严格说，取所有这些能量的下确界，也就是不超过它们的最大下界。这里的函数大小按平方值在球面上的平均来衡量。

这个目标同时固定了算子、函数条件和平均值约束。它不是随意在某个简化方程里挑最小数；一般也不能假定原算子作用后仍保持零均值。最终结论必须对应这个带约束的原题。

势函数与难点

势函数 q 是能量规则中随位置改变的一个函数，积分在这里可理解为把整个球面上各处的贡献按面积汇总。当前能量包含函数沿球面变化产生的代价，以及 q 乘上函数值的平方再积分得到的贡献，因此 q 可以改变不同位置的能量代价。

当前精度例使用 $q(z) = -1/|z|^{1/4}$ ，其中 $|z|$ 是 z 的绝对值， $1/4$ 次幂表示四次方根。越靠近赤道， q 的数值越趋向负无穷；这种局部无界行为称为奇异性，出现这种行为的位置称为奇点，这里实际上是一整条赤道。公式在赤道上不取有限值，所需积分及运算能否成立，需要单独检查。

4 | 已有成果：精度已经提高，自动研究尚待验证

为什么改变候选函数可能有用

函数表示是用一组较简单的函数来组合表达目标或候选的方法。乘在每个函数项前、决定其贡献大小的数称为系数。多项式是常数、一次幂、二次幂等非负整数次幂的有限组合。分数幂允许指数为分数，例如 $|z|^{7/4}$ 。当真实解在奇点附近有普通多项式难以表达的局部变化时，分数幂有时比普通多项式更容易描述它的形状。

本项目用有限个函数组合成候选，称为**试探函数**；这些允许组合出的候选构成**试探空间**。已有精度改进的重要来源，是开发者根据方程选择了更适合奇异结构的函数项。如何由系统自动做出这种选择，仍是后续研究问题。对最低谱值的上下界组成谱区间，两者之差称为**谱区间宽度**，下面用它报告精度。[P1-P4]

已保存的结果	它能说明什么
10 项分数幂候选，完整谱区间宽度约 1.00839×10^{-10}	在这个固定原題上，选对表示并检查证据能达到很高精度
16 项候选，宽度约 1.14556×10^{-18}	继续改进后获得更窄区间；不代表任意函数都能达到同样精度
98 项测试、66 条唯一数学记录检查通过	支持程序和证据的一致性；66 条包含相互关联的记录，不是 66 道独立题
1071 个历史文件保持未变	旧证据被保留，便于追查结果来自哪里

10^{-10} 表示一百亿分之一； 10^{-18} 写成小数时，小数点后前 17 位是 0，第 18 位是 1。这些数描述的是谱区间宽度，并非模型花费的时间。[P1、P2]

三种容易混淆的精度指标

函数逼近是用一个较容易处理的函数替代另一个函数。本项目的 L^2 误差，是把两函数各处差值平方，在整个球面按面积取平均，再开平方。它衡量整体差距，不保证每个位置的误差都小，也不直接等于最低谱值的误差。

残差是把候选代回目标方程后剩下的差。例如 Hu 应等于 λu 时，差为 $Hu - \lambda u$ 。完整残差检查原方程中所需的全部部分；只在有限个已选函数方向上检查得到的差，称为**投影残差**。后者可能很小，而遗漏方向上的差仍然很大。约束问题还必须按原題规定处理残差，不能机械套用公式。

因此，势函数 q 的 L^2 逼近误差、特征函数候选 u 的完整残差大小、最低谱值上下界的间距，是三个不同的量。投影残差只检查有限方向，更不能代替完整残差。只有与原題目标对应的证据，才能支持完成声明。

5 | 现有证据的范围：哪些结论还不能推出

保留效果较弱的路线，才能理解改进来源

矩在本项目中指原函数与指定函数组合后的积分值；直接矩路线直接计算这些值，而不先把原函数换成另一个近似函数。另一个算例中的跳跃势在赤道两侧分别取固定但不同的值，跨过赤道时突然改变。[P1]

直接矩路线在跳跃势上的最好已测区间宽度约为 9.58×10^{-6} ，在负奇异势上约为 1.40×10^{-4} ，均未达到当时 10^{-8} 的目标。保留这些结果，才能看出后来的分数幂方法解决了什么困难，而不是只看到成功记录。[P1]

此前约 1627 倍、135 倍和 1.35 亿倍的改善，都是指定内部比较中的区间宽度比。这些比较的计算内容和预算并不都相同，因此不能用来说明运行速度、模型消耗，或相对所有成熟方法的优势。[P1-P3]

当前验证依赖什么

有理数是可写成两个整数之比的数。精确有理计算用整数和分数进行运算，避免把每一步都舍入为有限位小数。当前验证器主要使用这种计算方式，但“算术精确”仍不等于“程序和数学推导不会出错”。

证据重放是重新读取保存的证书，检查其中的计算和结论。16 项候选的证书已经重放；这并不意味着重新执行了寻找候选的全部过程。还有一条额外检查没有执行：先把算子作用于候选所得的整个函数合并起来，再用直接积分重新核验。报告保留这个未完成项。[P2、P3]

形式化证明是把命题、所依赖的前提条件和推导写入严格规定的逻辑语言，再由证明检查程序逐步核对。支持这种工作的软件称为证明助手。本项目尚未接入证明助手，当前认证来自自有验证器。即使今后完成形式化证明，也仍需确认编码的命题忠实表达了原题。

下一阶段真正要补的证据

现有结果证明了某些计算和认证方法在固定题目上有效，尚未证明系统能自动发现合适表示、选择研究方向，并在陌生题中帮助较弱模型超过较强模型。真实跨模型对照及半小时／八小时挑战均未进行。[P4]

所以，下一步的主要问题应是“这些研究决定能否可靠地交给系统”，而不是仅仅继续增加同一道题的小数位数。已有高精度例仍有价值：它提供了可检查的起点，帮助比较不同研究动作。

6 | 先搭清工作逻辑：一次研究怎样推进

从原题出发，保留每次转换的理由

一个清楚的工作循环是：固定原题和完成标准，列出已知事实与缺口，提出少量候选动作，用小预算尝试，检查条件和证据，再决定保留、换路或停止。选择动作时，需要同时考虑它的预算与预期收益。

例如，区间仍太宽时，系统可以尝试增加一个函数项，也可以尝试加强下界。它应比较哪种动作更可能缩短完成原题所需的总时间，而不只比较哪一步给出了更漂亮的中间数字。

为了记录这些工作，可以建立研究图。图是一种由节点及连接节点的边组成的数据结构；这里的节点保存原题、候选、辅助结论或证书，边记录它们之间是什么关系。辅助引理是帮助证明主要结论的中间命题，需要有自己的依据。

关系	在研究图中的含义
等价	两个命题在注明条件下可以互相推出
蕴含	一个命题成立能推出另一个，反向不一定成立
给上界 / 给下界	只限制目标的一侧，不能替代完整答案
带余项的近似	近似之外还记录遗漏部分的界；遗漏部分称为余项
启发	提供值得尝试的想法，目前没有足够证明

新节点不能因为更容易计算就自动替代原题。原题的形状、允许函数、约束和目标都要保留，转换的条件则写在关系中。

五项职责，先分清再实现

原题管理负责保存问题和完成标准；策略提出负责产生可能的下一步；计算执行负责运行数学工具；证据检查负责判断结论受到多强支持；经验保存负责记录何时有效、何时失败、花费多少。

这五项是工作职责，暂时不要求做成五个独立程序。模型可以建议先尝试哪个方向，但它说“已经证明了”本身不能改变证据状态。系统也应区分程序错误、预算不足、方法太弱、条件不足和仍未知的数学缺口，避免把不同失败都处理成“再多算一些”。

7 | 四条研究路线：根据缺口选择下一步

路线 A：自动寻找更适合的函数表示

这条路线研究如何选择函数项、变量或区域划分，使少量计算更贴近问题的结构。把一个范围分成几块分别处理，称为分区；某个函数在小范围内用简单项来表达，称为局部展开。它们都可能帮助处理奇点附近的困难。

当前分数幂例支持“适合结构的表示能够有效提高精度”。下一步应检验系统能否自己提出合适项，并检查它们能否合法参与原题运算。如果每一道新题仍要由人手工告诉它关键项，自动选择的目标就没有达成。

路线 B：寻找能补上证明缺口的辅助引理

这条路线适合候选已经稳定、上下界却仍相距很远的情形。比如，有些残差估计还需要知道目标特征值与其他特征值之间有足够距离；这种距离称为谱隙。如果缺少谱隙的可靠下界，继续改善候选可能不如先研究这个条件。

有限计算还可能遗漏无穷多个函数方向，可理解为无穷多个可以分别调整系数的基本函数。这些没有显式保留的方向称为尾部；控制遗漏部分影响的估计称为尾界。系统可以倒推：要完成原题，究竟需要多强的谱隙或尾界？这个较小问题能否独立证明？如果引理实际等同于原题，或反过来依赖原题已经成立，就没有缩小困难。

路线 C：让一项研究服务一组相近问题

参数是用来描述问题变化的数值，例如奇异性的强弱。问题族是一组具有共同结构、只在参数或部分条件上变化的问题。先集中研究代表问题，称为离线准备；收到具体问题后利用准备结果求解，称为在线求解。“离线／在线”在这里区分准备阶段和使用阶段，不是指是否连接网络。

这条路线要保存结论适用的参数范围，以及从一个问题传到另一个问题的可靠依据。它特别适合反复求解相近问题，但准备成本和复用次数都要计算。如果几何形状或函数性质发生根本变化，原有结论可能失效。

路线 D：让系统搜索可复用的小算法

这条路线把“产生表示、构造证书、选择动作的方法”本身作为搜索对象。例如让模型修改一个生成函数项的小程序，再用固定任务检查新程序是否更有效。评估器是按事先规定的规则检查结果、计算成绩的程序；它与验证器可以部分重合，但成绩高不自动代表数学结论完整。

目前可优先小范围比较 A 与 B，因为已有案例同时暴露了表示不足和证明条件不足。C 在重复任务多时更有价值；D 则需要先有可靠的评估器。这是暂定次序，后续证据可以改变它，四条路线也可以相互衔接。

8 | 想法库：从改变问题到积累工具

先考虑怎样改变研究方式

想法 1：把同一目标换成更容易处理的表达。例如把“证明最小能量不低于某个数”改写为“证明所有允许函数的能量都不低于该数”。这解决的是下界任务；求出最小值还需要找到达到或逼近该界的候选。已有的等式饱和方法，会在规则允许的范围内保存和扩展多个等价表达，再选择适合计算的形式；它提供了组织思路，但不会自动覆盖所有数学转换。[R12]

想法 2：从方程推导应该使用的函数项。先分析奇点附近各项怎样相互影响，再提出分数幂或其他候选。这可能比盲目增加多项式中的最高幂次更有效，但局部预测必须回到整个原题中验证。

想法 3：让残差告诉系统该补什么。根据候选代回方程后的差，生成修正方向。平滑是减弱函数过于剧烈的局部变化；必要时先平滑再构造候选，因为残差本身未必处于所需定义域。真正的评价仍是最终区间是否收紧。

想法 4：选择最能区分失败原因的小实验。若怀疑表示太弱，就只改善表示；若怀疑下界太粗，就只加强下界。这样设计的判别性实验，目的在于区分几种解释，而不一定马上求出最终答案。如果诊断成本超过收益，就不值得保留。

再考虑怎样获得更有力的证明

想法 5：从完成目标倒推缺失引理。明确写出“只要再证明哪个条件、达到多强程度，就能完成”。这能使研究集中，但需要确认子问题比原题更容易，并且没有相互依赖的循环。

想法 6：主动寻找反例。反例是一个满足命题前提、却使结论不成立的对象。反例引导搜索先提出规则，再寻找击败它的例子，据此改进规则或增加必要条件。[R13] 数值上看似失败的例子需要复核；找不到反例也不等于证明成立。

想法 7：寻找一次约束全部对象的证书。可行域是满足原题条件的所有允许对象；全局最优表示在整个可行域中都没有更好的对象。与之相比，局部最优只排除了附近的改进。某些几何证明使用校准形式：一种特殊的面积比较工具，在规定几何条件下把候选与整类竞争曲面比较，从而证明它面积最小。[R14] 找不到这样的证书，只说明当前方法没有成功。

想法 8：优化证明的拆分方式。对容易处理的区域使用粗但可靠的估计，对接近失效条件的区域单独精算。收益来自减少不必要的工作，前提是证明这些部分覆盖了原题的全部情况。

9 | 想法库续：从相近问题得到可复用经验

利用形状变化理解困难

想法 9：从已经理解的几何逐步走向目标题。从球面或圆盘出发，一点点改变形状，每一步都验证已有界还能传递多远。这种逐步改变称为连续变形。如果两个特征值在变化中相遇或交换次序，称为谱交叉；它可能使原来的跟踪规则失效，不能继续机械套用。

想法 10：专门研究形状将要发生极端变化时的情形。例如两个大区域由越来越细的管道连接。某些尺寸趋于零、导致原有结构或估计失效的过程，称为几何退化；让参数趋向某个值后研究理想化对象，称为研究极限问题。极限可能揭示困难来自哪里，但要解决管道仍有正宽度的原题，还需给出有限宽度与极限之间的误差。

从案例中提炼简短而可靠的规律

想法 11：寻找少数决定困难程度的几何量。系统可以从例子中发现，某个尺寸或形状指标可能比其他信息更能预测结果。数据中经常一起变化的关系称为相关性；相关性本身不能证明因果，也不能证明普遍的数学规律。已有研究展示了利用数据帮助研究者形成数学直觉的路径。[R15]

想法 12：把反复成功的动作整理成工具。若多次出现“识别某种结构、执行同一变换、核对同一条件”的过程，可以把它整理成规则。新工具必须写出输入、适用条件、输出证据、失效情形和成本，再到未参与整理的新题中检验。

怎样从十二个想法中选择

研究假设是尚待检验的解释或预期，例如“当前区间太宽主要因为遗漏了奇异项”；它不能作为已经证明的事实参与后续论证。每轮只选一个主要研究假设，说明它针对哪个缺口、预计节省什么工作，以及怎样判断它失败。

新方向可以来自失败，也可以来自数学推导或新文献。当前十二个想法是候选研究动作，不要求全部实现。能长期保留的工具，应当在节省的时间或提高的完成率上，超过选择、检查和维护它所增加的开销。

10 | 参考项目：理解它们分别解决哪一部分

提出数学步骤，并检查能否推进证明

AlphaGeometry 是一个平面几何解题系统：模型提出辅助点或线，规则推理程序尝试接着推导证明；AlphaGeometry2 是其后续版本，简称 AG2。它们提示我们把“提出值得尝试的动作”和“判断动作是否合法”分开。它所使用的点、线等几何对象表达方式，不能直接处理这里的球面函数、方程与不等式；AG2 已公开的主要部分是按明确规则推理的符号核心。[R1]

Lean 是一种证明助手。LeanDojo 是支持模型与 Lean 证明环境交互的工具和数据基础；ReProver 是配套的证明系统，会查找相关前提、尝试步骤，并根据 Lean 的反馈继续搜索。检索就是根据当前需求从资料中找到可能相关的内容。这组工作值得借鉴之处，是让模型看到明确的证明进展与失败反馈。[R2]

DeepSeek-Prover-V2 是面向形式化数学证明的语言模型及配套研究方法，其方法包含把证明分成较小引理、完成后再组合。AlphaProof 是结合学习与形式化证明搜索的系统，会围绕目标构造相关问题并进一步训练。它们启发我们在卡住时改变研究任务，但其训练投入与公开内容不能忽略；论文描述不等于整个系统都可直接运行。[R3、R4]

LeanEuclid 是把平面几何的文字命题转成形式化表达，并结合图形推理进行处理的框架。它提醒我们检查“被证明的命题是否还是原题”。其部分判断借助外部逻辑求解器，也就是自动检查规定逻辑条件的程序；这会增加需要信任的环节，不能把所有检查都归为 Lean 自身完成。[R11]

搜索生成答案的方法

FunSearch 是用语言模型反复改进小程序，并通过实际运行挑选有用版本的研究系统。它保存多个程序候选，称为种群；候选经历修改、评估和保留，这种循环称为进化搜索。值得借鉴的是把“生成规则”作为研究对象。它公开了部分核心代码，生成模型和完整运行环境仍需另行准备。[R5]

AlphaEvolve 是结合模型生成代码和自动评估的算法发现系统；其公开资料主要提供结果与验证材料，不能当作完整系统。ShinkoEvolve 是同类的程序进化框架，包含候选分组、组合修改、模型选择和经验反馈。它们启发我们尝试不同路线并计算成本，但程序成绩高、或与已有代码不同，都不能自动说明数学上原创。[R6、R7]

11 | 参考项目续：管理计算表示与可靠范围

函数怎样表示，决定计算是否容易

Chebfun 是把函数表示为可计算近似、并自动调整表示精度的软件；Sphrefun 是其中处理球面函数的工具。自适应程序根据当前误差或反馈，调整项数、分区或方法，而不是从头到尾使用固定设置。它们是管理函数表示的强参考，但数值上看似充分精细，不自动等于已经获得严格误差保证。[R8]

pyMOR 是帮助建立和使用较小计算模型的软件库。用较少的待求数值或函数项替代原来的大规模计算，称为降阶。它借助离线准备、在线复用和误差估计处理相近任务，适合参考路线 C。不过，缩小模型引入的误差只是原题误差的一部分；其他近似或遗漏仍须单独处理。[R9]

搜索程序和证明判断应各负其责

IntervalRootFinding.jl 是用区间方法寻找方程根的程序库。方程根是让方程两边相等的输入值；区间计算在每一步使用包含真实值的范围，而不只使用单个小数。这个库将区域搜索和可靠判定分开，并保留“尚不能判断”的状态，值得借鉴。[R10]

这类有限区域的检查，不能自动处理本项目所有可能的函数。若待求对象可由有限个独立数值完全确定，称为有限维问题；允许无穷多个独立变化方向的函数空间，称为无限维空间。即使原题只给出几个参数，待求函数仍可能属于无限维空间。从有限计算回到后者，必须有尾界或其他完整覆盖论证。

怎样使用这些参考资料

以上十一组项目各自解决了部分困难：有的帮助提出证明步骤，有的搜索程序，有的管理数值表示或检查范围。它们组合后是否更有效，需要与直接使用成熟工具进行比较，不能从模块数量推断收益。

阅读公开资料时，还应区分公开程度。模型权重是训练得到的模型内部数值参数；伪代码是用于说明算法步骤、未必能直接运行的描述；源码是程序实现；结果验证代码主要用于检查已给出的结果。公开其中一种，不等于公开完整可运行系统，也不表示本项目已复现作者报告的成绩。

12 | 先规定完成标准，再设计比较

不同数学任务需要不同验收

验收标准是在实验之前写清的完成条件。精度任务可以要求“原目标位于某个宽度不超过 10^{-8} 的有效区间内”；证明任务可以要求完整证明，或一条事先认可、确实推进原题的关键引理；探索任务可以要求经复核的反例、改进的界或可复用构造。

开放问题指截至注明日期，相关文献尚未给出所要求答案的问题。已解决的困难题适合检验系统能否找到方法；开放问题适合检验局部进展是否有价值。当前固定奇异势算例属于开发与检查工具的例子，不能据此声称解决了重大开放问题。

有些引理发现和概念探索没有便宜的自动评分方法，仍应保留。可以事先规定阶段性成果，再由人复核。难以用一个数评分，不代表研究没有价值；但不能因此省去完成条件。

全局目标不能被较小问题代替

在固定试探空间中找到了最好候选，只说明它优于这个空间内的竞争者。要证明原题的全局最优，还需要排除空间外的所有允许对象。同样，有限多个成功样本不能覆盖整个连续参数范围，某个局部计算达标也不能替代全部情况达标。

最终关键结果应尽可能由不同检查路径复核。如果搜索与检查共享同一公式或同一代码，要注明这项依赖，不能称为完全独立。自然语言说明、数值支持、自有验证器认证和形式化证明，应分别标明；结论强度必须与证据相符。

新题应如何保留

开发集是可以用于修改工具的题目；验证集用于比较和选择策略，也会影响开发；最终测试集在策略确定之后才用于评估，不能预先针对它改进工具。事先不让某些题参与开发，称为留出；在更广泛新题中仍有效的能力，称为泛化能力。

只改变少量参数的新题，可以检查问题族内部的迁移；整类没有参与开发的问题，才能提供更强的跨结构证据。两者应分开报告。如果最终测试结果被用来定位弱点或改进方法，这些题就变成开发资料，下一次泛化判断需要新的独立题目。

模型训练时可能已经接触公开题或相关答案，这种影响测试独立性的情况称为训练污染。通常无法完全排除，应记录来源与已知情况，不宣称无法证明的“模型绝对没见过”。

13 | 公平比较：怎样确认优势来自工具

先固定条件，再看结果

实验前固定题目、资料权限、验收标准、预算及模型和工具版本。**对照实验**是在尽量保持其他条件相同的情况下，改变要研究的因素并比较结果。例如同一模型分别使用旧工具和新工具，才能帮助判断工具变化带来了什么。

比较对象	常规工具	旧项目工具	新框架工具
较低成本模型	判断原有能力	判断版本变化	检验目标系统
较强模型	跨模型主要基线	辅助解释差异	检查新工具是否也帮助强模型
无语言模型的程序策略	按适用性加入	检查已有自动化	判断模型决策是否增加价值

常规工具应包括合理的编程、资料检索和数学计算能力。不能只允许较强模型徒手推理，却让较弱模型使用大量专用工具，再把差距解释成普遍优势。完整比较可以分阶段做，但提出某项结论前，必须补齐支持它的对照。

把成功、失败与波动一起记录

主要指标是**成功率**，即给定预算内通过验收的任务数占全部任务数的比例。还应记录完成所需时间和费用。相同时间预算与相同费用预算回答不同问题，应分别比较；超时和失败不能从统计中删除。

如果系统含有随机选择，同一题重复运行可能得到不同结果，应报告各类结果出现的次数、完成时间的波动，以及样本量对判断的限制，而不只报告最好一次。**消融实验**是暂时移除某个部分，再观察结果如何改变，例如移除残差反馈，判断收益是否确实来自它。

工具使用的预制模板、人工提示及已知证明都要登记。模型版本或重要工具发生变化时，应重新建立相关基线。希望达到多大的实用改善，也应在看见结果之前确定，避免事后只挑有利指标。

什么时候进行半小时／八小时挑战

先用较小规模实验确认工具有稳定价值，再投入长时间挑战。任务组、版本、资源条件和成功标准都提前固定。一次成功可以提供线索，但稳定的跨模型优势需要可重复的比较；如果不调用模型的程序策略同样有效，也应如实保留这个发现。

14 | 成本：减少无效研究比缩短文字更重要

分清首次投入与反复使用

应同时记录首次解决新问题的成本、准备完成后再解决一道题的新增成本，以及包含研发和维护的累计成本。第二项称为**边际成本**。同一问题族的平均成本可写为：

每题平均总成本 = (离线准备 + 全部在线求解 + 维护的成本) ÷ 已处理题数。

例如准备花 100 个成本单位，以后每题花 1 个单位，处理 10 题的平均成本是 11，处理 100 题则是 2。这个教学例子说明复用次数很重要；实际报告还必须同时给出成功率和失败次数。计算每个成功任务的成本时，失败消耗也要计入。

token 到底在衡量什么

token 是语言模型把文字切分后处理的基本片段，可能是一个字、一个词的一部分或标点，并不等于固定数量的汉字。词表及相应切分规则决定文字如何编码。模型服务报告的输入、输出和可获得的内部推理用量，应与仅对可见文字做的长度估算区分。不可获得的用量记为未知。

此前实验只测量公开编码规则下可见文本的长度：相对完整文件节省约 93.6%，相对合理精简版本仅约 18.4% 或 15.4%；另有小题组反而增加约 11.2% 或 18.9%。这些不是实际跨模型推理成本的测量。[P4、P5]

缓存是保存已经计算或处理过的内容，以便以后复用。节省 token 可以来自减少重复探索、复用已验证结论、让程序执行常规循环，以及精简工具返回的结果摘要。摘要仍要保留目标、条件、界的方向、证据状态和查阅入口，并测试模型是否理解，补读详情之后总成本是否仍降低。

并行会缩短等待，但不一定减少总成本

agent 在本文中指能够接受子任务、调用工具并反馈结果的模型工作单元。并行是让多个工作单元同时处理不同任务；墙钟时间是现实中从开始到结束的等待时间。并行可能缩短墙钟时间，却增加所有分支合计的计算量。

用户授权最多 18 个 agent，这只是上限。适合并行的是不同假设、独立检查和互不依赖的候选路线。全部分支的模型消耗、工具时间、失败重试和人工参与都应计入。每次比较还要记录所用硬件、实际同时运行的单元数、模型实际费用，以及单独计费的缓存用量；无法取得的数据记为未知。负责分配预算的程序本身也有成本，复杂调度必须比简单策略产生额外收益。

15 | 迭代与原创性：每轮回答一个明确问题

怎样开展一轮有意义的迭代

迭代是根据上一轮结果修订方法，再开展下一轮检查。每轮应遵循：真实失败或新假设，提出最小改动或实验，设置固定对照，复核结果，决定保留、修正或撤销。新的想法也可以来自文献和数学推导，不必等到失败才研究。

当前阶段	需要回答的问题	转向或停止的信号
可信性	证据真的对应原题吗？	验证器接受错误证书，先修复
单项价值	改进是否超过新增成本？	只在刻意弱化的基线前有效
迁移	策略固定后能处理新题吗？	每题仍需人工改关键规则
跨模型优势	实用优势能重复出现吗？	长期无净收益而复杂度持续增长
长期积累	复用是否抵消维护成本？	保存的内容越多，选择与检查越困难

过拟合是方法过度适应开发题目的细节，以至于换题后效果下降。新增工具必须说明它改善哪个环节，并用留出题防止过拟合。版本号用于追踪改动；修改参数或增加文档，不自动构成一个新的数学算法。

原创性要分别证明

原创性指相对于已有工作具有可确认的新内容，需要查阅最接近的研究再判断。数学贡献可以是新命题、新证明或新的适用范围；算法贡献可以是新的自动决策方法或可靠的效率改进；工具价值则可以是在相同条件下让任务完成得更好。这三者需要不同证据。

当前使用的数学基础都有先例，包括根据奇点选择函数项的方法。Temple 残差界在适用条件成立时，利用候选能量、完整残差及同一规定空间内相邻谱值的可靠界，给出最低谱值下界；Schur 约化是把相互影响的部分拆开，将一部分的影响归入另一部分再分析的方法；球面插值不等式连接球面函数的不同大小度量与变化能量；二次型是由输入分量的两两乘积组合成的表达；在这里是它对函数的相应形式，函数整体放大两倍时，能量值会放大四倍，相对二次型估计用一个已知能量式控制另一个能量项。这些方法的条件都不能省略。[R16-R20]

目前可确认的定位，是基于已有数学方法、可供复核的专用工具原型。值得继续研究的新内容包括自动生成合法表示、从认证失败找到有用引理，以及将结论可靠地复用到新题。自行写代码不等于发明数学方法，搜索没有发现相同实现也不等于已经证明首创。[P6]

16 | 后续交接：让新人能够接着做研究

开始下一轮之前

先确认长期目标，再读取当前证据和最近一次决策。原始结果保留，新实验另行记录。若改变验收标准，写明原因，不按新标准回头把旧失败改称成功。可复现指其他人能根据保存的输入、版本、步骤和条件重新检查关键结果；因此，代码之外还需要这些记录。

每轮记录项	用普通语言写清楚
原题与验收	研究什么？允许哪些对象？怎样算完成？
当前缺口	什么已经有依据？什么仍不确定？
研究假设	这次动作为什么可能有效？
对照与预算	与谁比较？有哪些资料和资源？
结果与证据	成功、失败还是超时？凭什么判断？
适用范围	哪些条件下能复用？何时会失效？
下一步决定	保留、修改还是撤销？依据是什么？

一项成果怎样逐步升级

单题技巧变成工具，需要明确输入和条件，并经新题检验。工具组织成框架，需要证明这种组织额外带来收益。框架形成跨模型能力主张，需要真实模型对照。提出学术原创主张，则需要另行建立文献与数学证据。每一步都应保留前一步的证据，而不是依靠名称升级。

发布项目时，应给出方法来源、第三方材料说明、失败记录、验收范围和可复现入口。本报告提供后续判断原则，不构成穷尽全部文献的原创性鉴定。

下一阶段的三个具体问题

1. 系统能否自动选择合适函数项，并减少达到相同认证精度的总成本？
2. 精度停滞时，它能否判断应该改候选，还是补充证明条件？
3. 一道题留下的方法，能否在没有人工补答案的新题中可靠复用？

这三个问题把原始雄心连接到可开展的实验。后续研究可以分别推进，依据结果选择框架；不需要在证据出现之前决定完整系统的所有细节。

附录 A | 项目证据与阅读入口

[P1] 最新精度研究。固定球面问题、函数逼近与谱界的全部结果及范围：精度报告 (../geometry_precision_followup/REPORT.md)。

[P2] 最新验收记录。98 项测试、66 条唯一数学记录重放、结果绑定及历史文件一致性：VALIDATION.json (../geometry_precision_followup/VALIDATION.json)。该记录不是模型效率评测。

[P3] 独立数学审查。定义域、完整残差、不同函数方向的覆盖，以及额外独立核验未完成项：DIRECT_MOMENT_REVIEW.md (../geometry_precision_followup/DIRECT_MOMENT_REVIEW.md)。

[P4] 模型能力评测状态。已完成与未完成的模型对照边界：MODEL_EVALUATION_STATUS.md (../geometry_v36_v90/MODEL_EVALUATION_STATUS.md)。

[P5] 旧 token 工程结果。编码词表、比较基线、负收益与实验范围：V36-V90 报告 (../geometry_v36_v90/REPORT.md)。

[P6] 原创性检查。方法先例、贡献分类、代码来源检查边界：原创性报告 (../geometry_originality_audit/REPORT.md)。

[P7] 框架讨论与项目调研。框架讨论稿 (../geometry_framework_brainstorm/Framework.md)；相似项目与框架参考 (../geometry_framework_brainstorm/REFERENCE_PROJECTS.md)。

Markdown 是用普通文本和少量标记保存标题、段落、链接的文档格式，本报告的可编辑原稿使用这种格式。本地证据路径相对于原稿所在目录。PDF 是固定页面版式的文档格式，用于阅读与共享；查验完整实现和证书时应保留项目目录结构。报告使用上述记录形成当前事实基线，不将未来建议写成已实现功能。

附录 B | 框架与工具参考资料

[R1] AlphaGeometry / AlphaGeometry2。原版代码与搜索说明；AG2 符号核心。

[R2] LeanDojo / ReProver。论文；公开实现。

[R3] DeepSeek-Prover-V2。论文方法；官方材料。

[R4] AlphaProof。Nature 论文、方法及代码公开范围。

[R5] FunSearch。Nature 原论文；官方代码。

[R6] AlphaEvolve。白皮书；结果与验证代码。

[R7] ShinkaEvolve。论文；Sakana AI 官方实现。

[R8] Chebfun / Sphrefun。奇点处理；球面表示。

[R9] pyMOR。技术架构；架构论文。

[R10] IntervalRootFinding.jl。搜索与判定机制；保证状态。

[R11] LeanEuclid。国际机器学习大会论文；实现与外部程序检查范围说明。

附录 C | 数学方法与拓展思路参考

[R12] 等式饱和：保存并扩展等价表达的搜索方法。Willsey 等，egg: Fast and Extensible Equality Saturation。论文。用于借鉴等价表示搜索，不表示一般数学转换都已可自动处理。

[R13] 反例引导。Solar-Lezama，关于从需求自动构造程序、再用反例改进候选的课程资料。作者课程资料。

[R14] 几何全局证书。Harvey、Lawson，Calibrated geometries，1982。原论文。

[R15] 数据引导数学直觉。Davies 等，Advancing mathematics by guiding human intuition with AI，2021。原论文。

[R16] 奇点适配谱基：选择与奇异结构相配的基本函数，组成求解特征值问题的表示。Li、Zhang，Efficient Spectral and Spectral Element Methods for Eigenvalue Problems of Schrödinger Equations with an Inverse Square Potential。作者预印本。

[R17] Müntz 谱方法：使用允许非整数指数的幂函数组合求解相关问题的方法。Yang、Wang、Li、Sheng，Müntz ball polynomials and Müntz spectral-Galerkin methods for singular eigenvalue problems。作者预印本。

[R18] Temple 与相对二次型。Teschl，Mathematical Methods in Quantum Mechanics，第 4.13 条定理及第 6.5 节。作者书稿。

[R19] Schur 谱约化。Dusson、Sigal、Stamm，Analysis of the Feshbach-Schur method for the Fourier Spectral discretizations of Schrödinger operators。作者预印本。

[R20] 球面插值。Dolbeault、Esteban、Kowalczyk、Loss，Sharp interpolation inequalities on the sphere: new methods and consequences。作者预印本。

引用用于说明已有机制、可借鉴设计和数学基础。各项目公开范围按本轮检索记录理解；本文不把作者报告的成绩当成本项目已复现的结果，也不把组合这些方法本身作为首创证明。